Checkpoint 4: Clasificación con fine-tuning eficiente (LoRA)

Data Science III | MariaLorena Gomez | Dataset: AG News (4 clases)

1. Resumen de arquitectura

Modelo base: distilbert-base-uncased (Hugging Face Hub), Transformer encoder de 6 capas, 12 cabezas de atención, 768 dimensiones, ~66 M parámetros. **Justificación:** el corpus está en inglés (modelo uncased en inglés, vocabulario WordPiece de ~30k), las noticias son cortas (percentil 95 = 71 subpalabras, max_length = 71) y DistilBERT retiene ~97% del desempeño de BERT-base con 40% menos parámetros y mayor velocidad, lo que entra en una GPU gratuita (Colab/Kaggle: Apple MPS (GPU del Mac)). El modelo recibe texto con limpieza estructural (sin lematizar), porque el tokenizer WordPiece y la atención aprovechan la puntuación, las formas flexionadas y las stop-words.

2. Configuración PEFT / LoRA

Hiperparámetros	Valor	Argumento
rango r	8	Tarea simple (4 clases temáticas): un rango bajo captura la adaptación necesaria con pocos parámetros.
alpha	16	Factor de escala alpha/r = 2.0; criterio habitual alpha = 2r.
target_modules	q_lin, v_lin	Proyecciones query y value de la autoatención (q_lin, v_lin en DistilBERT).
modules_to_save	pre_classifier, classifier	Cabeza de clasificación nueva: se entrena completa.
lora_dropout	0.1	Regularización de los adaptadores.
learning rate / epocas / batch	0.0002 / 3 / 32	LR mayor que en full fine-tuning (2e-5) porque solo se entrenan los adaptadores.

3. Parámetros

Parámetros del modelo original	Parámetros entrenables (LoRA + cabeza)	% entrenable
66,956,548	741,124	1.09%

4. Entrenamiento

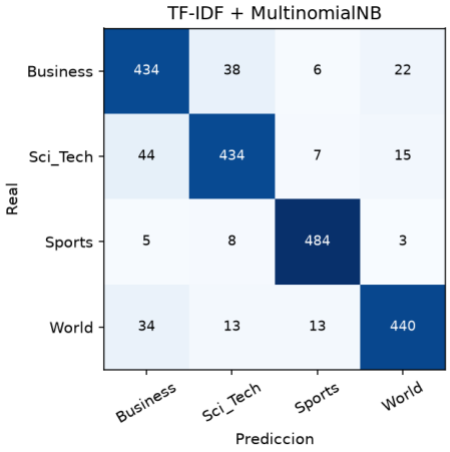
Época	Val loss	Val F1 macro
1	0.2668	0.9099
2	0.2577	0.9161
3	0.2578	0.9170

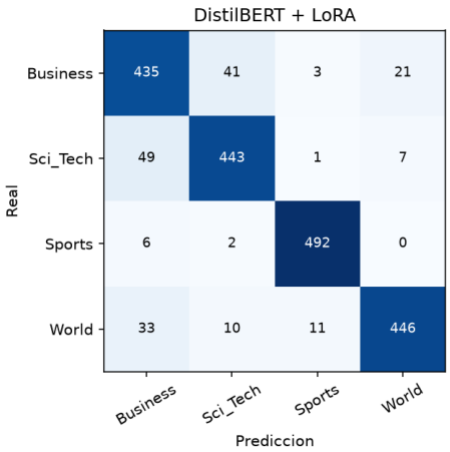
Perdida final de entrenamiento: 0.2724 | perdida final de validación: 0.2578. Tiempo de entrenamiento: 3.7 min en Apple MPS (GPU del Mac). Validación = 10% estratificado del train; el test no se uso para decidir nada.

5. Resultados y comparativa (mismo ag_news_test.csv, 2.000 noticias)

Métrica	A: TF-IDF + MultinomialNB	B: DistilBERT + LoRA
Precisión (macro)	0.8964	0.9091
Recall (macro)	0.8960	0.9080
F1 (macro)	0.8960	0.9082
Precisión (weighted)	0.8964	0.9091
Recall (weighted)	0.8960	0.9080
F1 (weighted)	0.8960	0.9082
Accuracy	0.8960	0.9080

Las clases están balanceadas, por lo que macro y weighted coinciden. Eficiencia: TF-IDF entreno en 0.2 s (CPU); LoRA en 219 s (GPU), un 1371 veces más tiempo.





6. Conclusión técnica

La diferencia de F1 macro del Transformer respecto del baseline es +0.0122. En este corpus, el Transformer + LoRA aporta una mejora moderada: el costo adicional se justifica solo si cada punto de F1 es valioso para el negocio. La confusión principal del baseline es Sci_Tech vs Business (44 casos) y la del Transformer es Sci_Tech vs Business (49 casos). LoRA permite adaptar el modelo entrenando solo 1.09% de los parámetros y guardar un adaptador liviano.