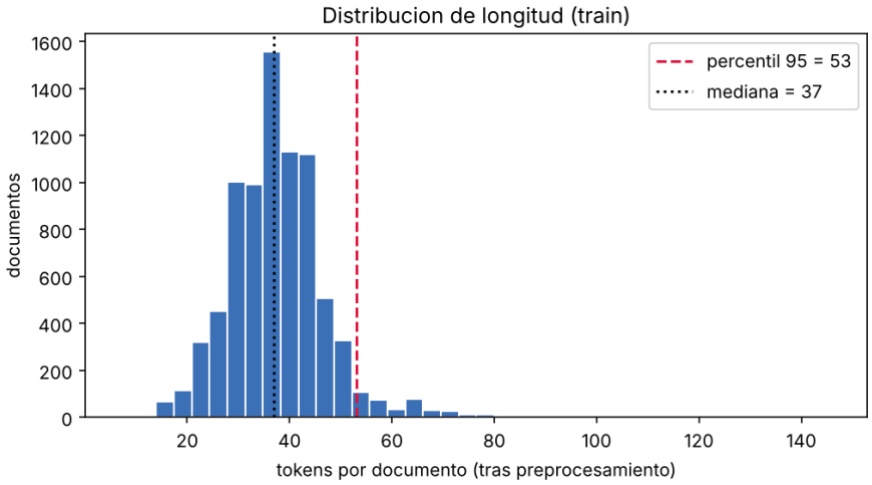
EDA de texto: corpus preprocesado listo para modelado

Data Science III - Pre-entrega Módulo 2 | Dataset: AG News | María Lorena Gómez (Com. #102200)

1. Resumen del pipeline de preprocesamiento

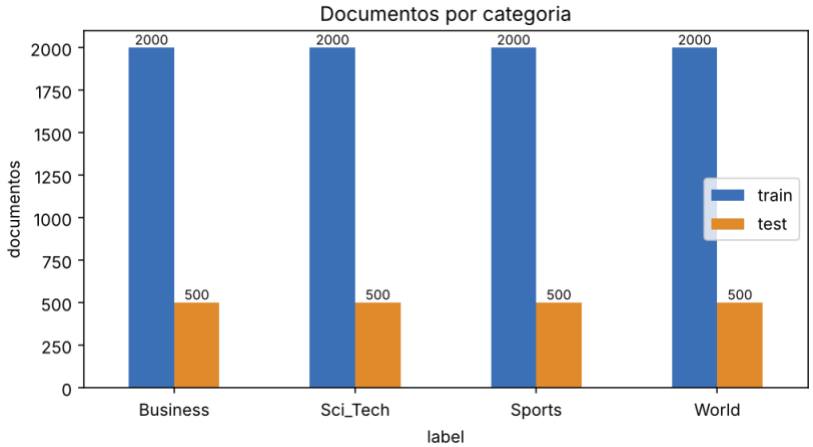
La función **preprocess_text(text)** aplica, en este orden: (1) **limpieza Regex**: decodifica entidades HTML (<, >), repara entidades numéricas sin '&' (#39; = apostrofe, #36; = $, #151; = guion), elimina tags HTML y URLs y colapsa espacios; (2) **normalización**: minúsculas, siglas (U.S. a us), posesivos 's, y descarte de puntuación; (3) **lematización** con spaCy (en_core_web_sm), conservando tokens alfabéticos y numéricos. Las stop-words no se eliminan aquí (se miden en el EDA y se filtran solo en los modelos clásicos). Se aplico a las 8.000 noticias de train y 2.000 de test, de forma idéntica. **Lematizador de esta corrida:** reglas simples (fallback, spaCy no instalado). Ruido (entidades/tags/URLs) en train: 2639 documentos antes, 0 después. Además se eliminan las firmas de agencia ('(AP) AP -', '(Reuters) -', 'Quote, Profile, Research'), presentes en 1688 documentos: duplicaban n-gramas ('ap ap', 'reuters reuters') sin aportar contenido temático.

2. Longitud de documentos y percentil 95



Tokens por documento: media 37.7, mediana 37, min 7, max 146. **Percentil 95 = 53 tokens** (max_len de referencia): cubre el 95% de las noticias sin truncar.

3. Distribución de clases



Las cuatro clases están perfectamente balanceadas en train (2.000 c/u) y en test (500 c/u). Consecuencia para M3 y M4: no se requiere class_weight; F1 macro = F1 weighted.

4. Top 20 bi-gramas y tri-gramas (scikit-learn, sin stop-words)

#	Bi-grama	Frec.
1	new york	419
2	oil price	197
3	unit state	168
4	prime minister	139
5	official said	113
6	said thursday	101
7	said monday	99
8	said tuesday	98
9	red sox	98
10	los angele	96
11	san francisco	96
12	president bush	93
13	said wednesday	90
14	year old	88
15	said friday	88
16	sport network	74
17	mobile phone	72
18	microsoft corp	71
19	wall street	71
20	world cup	69

#	Tri-grama	Frec.
1	new york stock	37
2	boston red sox	37
3	security exchange commission	26
4	prime minister ariel	26
5	minister ariel sharon	25
6	delta air line	22
7	state colin powell	22
8	secretary state colin	22
9	new york yankee	22
10	president vladimir putin	21
11	president george bush	21
12	high oil price	20
13	crude oil price	20
14	international space station	18
15	wal mart store	18
16	prime minister tony	17
17	minister tony blair	17
18	st louis cardinal	16
19	los angele dodger	16
20	washingtonpost com washingtonpost	16

Interpretación: los n-gramas son entidades y frases típicas de prensa (organizaciones, agencias, cargos y eventos), sin tags HTML ni fragmentos como 'amp', 'lt' o '39'. Los bigramas reflejan los cuatro temas del corpus (mundo, deportes, negocios, ciencia/tecnología).

5. Top 50 palabras más frecuentes y stop-words

#	Palabra	Frec.	Stop?	#	Palabra	Frec.	Stop?
1	the	13698	si	26	his	940	si
2	to	7971	si	27	was	924	si
3	a	7233	si	28	over	803	si
4	of	6578	si	29	be	777	si
5	in	6363	si	30	have	776	si
6	and	4637	si	31	their	733	si
7	on	3773	si	32	up	713	si
8	for	3410	si	33	two	675	si
9	that	1932	si	34	first	673	si
10	with	1771	si	35	company	653	
11	as	1719	si	36	are	646	si
12	at	1669	si	37	say	625	
13	new	1647		38	world	609	
14	its	1501	si	39	he	599	si
15	it	1437	si	40	but	598	si
16	is	1395	si	41	1	589	
17	us	1389	si	42	one	582	si
18	by	1357	si	43	more	578	si
19	said	1352		44	game	557	
20	has	1263	si	45	report	555	
21	from	1221	si	46	2	549	
22	an	1194	si	47	out	548	si
23	will	1011	si	48	this	543	si
24	year	969		49	oil	519	
25	after	947	si	50	monday	518	

De las 50 palabras más frecuentes, **38 son stop-words** (lista ENGLISH_STOP_WORDS de scikit-learn). Vocabulario: 17499 tipos; 6528 aparecen una sola vez.

6. Conclusión

El corpus tiene 8000 noticias de entrenamiento y 2000 de test, con 4 categorías perfectamente balanceadas (Business 2000, Sci_Tech 2000, Sports 2000, World 2000); por eso Accuracy y F1 serán equivalentes y no hace falta ponderar la perdida ni re-muestrear. El principal desafío fue el ruido de codificación: 2639 documentos de train traian entidades HTML escapadas ('<b>'), fragmentos rotos como '#39;' en lugar del apostrofe y URLs; además 1688 traian firmas de agencia repetidas. El pipeline las decodifica con Regex (html.unescape y reemplazo de entidades numéricas), elimina tags y URLs y normaliza espacios; tras la limpieza quedan 0 documentos con ruido residual y los N-gramas ya no muestran artefactos. Los textos son cortos (mediana 37 tokens, media 37.7); el percentil 95 es 53 tokens, valor que se propone como max_len de referencia (en M4 se recalcula en sub-palabras). En el top 50 de palabras, 38 son stop-words: confirma la cola dominada por palabras funcionales, que en los modelos clásicos se filtran (TF-IDF con stop_words) y en el Transformer se conservan. El vocabulario lematizado es de 17499 tipos, con 6528 que aparecen una sola vez (cola larga), lo que justifica limitar max_features en TF-IDF y usar sub-palabras en el Transformer. Lematizador usado: reglas simples (fallback, spaCy no instalado).