Checkpoint 4: clasificacion con fine-tuning eficiente (LoRA)

Data Science III | MariaLorena Gomez | Dataset: AG News (4 clases)

1. Resumen de arquitectura

Modelo base: distilbert-base-uncased (Hugging Face Hub), Transformer encoder de 6 capas, 12 cabezas de atencion, 768 dimensiones, ~66 M parametros. **Justificacion:** el corpus esta en ingles (modelo uncased en ingles, vocabulario WordPiece de ~30k), las noticias son cortas (percentil 95 = 71 subpalabras, max_length = 71) y DistilBERT retiene ~97% del desempeno de BERT-base con 40% menos parametros y mayor velocidad, lo que entra en una GPU gratuita (Colab/Kaggle: Apple MPS (GPU del Mac)). El modelo recibe texto con limpieza estructural (sin lematizar), porque el tokenizer WordPiece y la atencion aprovechan la puntuacion, las formas flexionadas y las stop-words.

2. Configuracion PEFT / LoRA

Hiperparametro	Valor	Argumento
rango r	8	Tarea simple (4 clases tematicas): un rango bajo captura la adaptacion necesaria con pocos parametros.
alpha	16	Factor de escala alpha/r = 2.0; criterio habitual alpha = 2r.
target_modules	q_lin, v_lin	Proyecciones query y value de la auto-atencion (q_lin, v_lin en DistilBERT).
modules_to_save	pre_classifier, classifier	Cabeza de clasificacion nueva: se entrena completa.
lora_dropout	0.1	Regularizacion de los adaptadores.
learning rate / epocas / batch	0.0002 / 3 / 32	LR mayor que en full fine-tuning (2e-5) porque solo se entrenan los adaptadores.

3. Parametros

Parametros del modelo original	Parametros entrenables (LoRA + cabeza)	% entrenable
66,956,548	741,124	1.09%

4. Entrenamiento

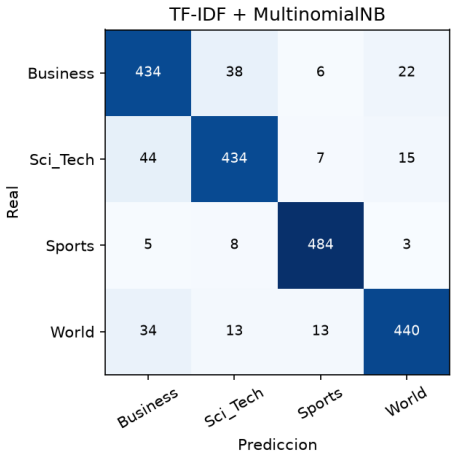
Epoca	Val loss	Val F1 macro
1	0.2668	0.9099
2	0.2577	0.9161
3	0.2578	0.9170

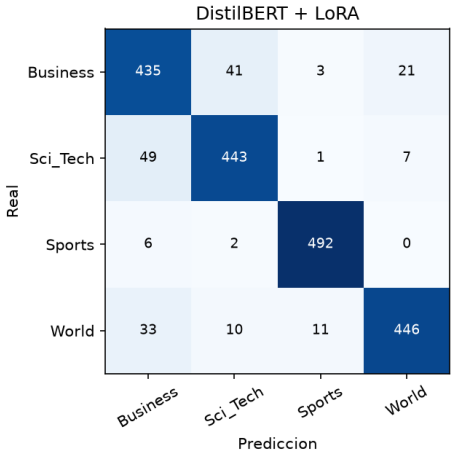
Perdida final de entrenamiento: 0.2724 | perdida final de validacion: 0.2578. Tiempo de entrenamiento: 3.7 min en Apple MPS (GPU del Mac). Validacion = 10% estratificado del train; el test no se uso para decidir nada.

5. Resultados y comparativa (mismo ag_news_test.csv, 2.000 noticias)

Metrica	A: TF-IDF + MultinomialNB	B: DistilBERT + LoRA
Precision (macro)	0.8964	0.9091
Recall (macro)	0.8960	0.9080
F1 (macro)	0.8960	0.9082
Precision (weighted)	0.8964	0.9091
Recall (weighted)	0.8960	0.9080
F1 (weighted)	0.8960	0.9082
Accuracy	0.8960	0.9080

Las clases estan balanceadas, por lo que macro y weighted coinciden. Eficiencia: TF-IDF entreno en 0.2 s (CPU); LoRA en 219 s (GPU), unas 1371 veces mas tiempo.





6. Conclusion tecnica

La diferencia de F1 macro del Transformer respecto del baseline es +0.0122. En este corpus, el Transformer + LoRA aporta una mejora moderada: el costo adicional se justifica solo si cada punto de F1 es valioso para el negocio. La confusion principal del baseline es Sci_Tech vs Business (44 casos) y la del Transformer es Sci_Tech vs Business (49 casos). LoRA permite adaptar el modelo entrenando solo 1.09% de los parametros y guardar un adaptador liviano.