Proyecto final: clasificacion de noticias con TF-IDF vs. Transformer + LoRA

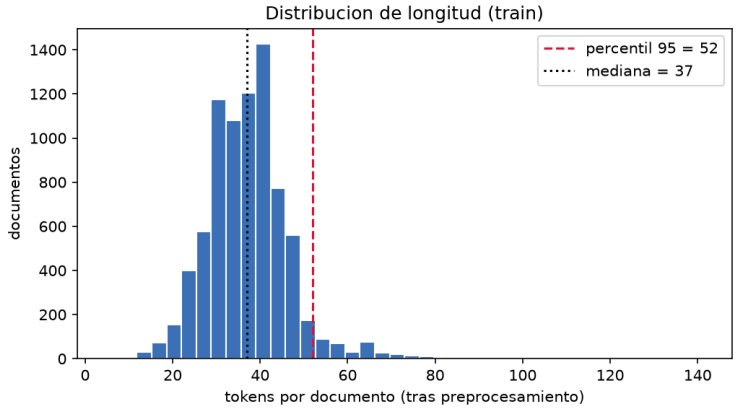
Data Science III - Capstone Report | MariaLorena Gomez

1. Definicion del problema

Objetivo: clasificar noticias en ingles en 4 temas (World, Sports, Business, Sci_Tech) con el dataset AG News de la catedra (8000 noticias de train, 2000 de test, clases perfectamente balanceadas). El caso de negocio es el enrutamiento automatico de contenido editorial. La pregunta que ordena el informe: **cuanto aporta, y a que costo, un Transformer adaptado con LoRA frente a un baseline clasico bien construido**, evaluados sobre exactamente el mismo test.

2. Pipeline de preprocesamiento

El EDA detecto ruido de codificacion en 2639 documentos de train (entidades HTML escapadas, '#39;', URLs). **Baseline:** limpieza Regex, minusculas, lematizacion con spaCy (spaCy en_core_web_sm), y TF-IDF de scikit-learn con stop-words en ingles. La longitud mediana es 37 tokens y el percentil 95 es 52 (palabras lematizadas). **Transformer:** solo limpieza estructural (sin lematizar ni quitar stop-words) y tokenizacion WordPiece de distilbert-base-uncased con truncation a max_length = 71 (percentil 95 en subpalabras = 71), padding dinamico por batch y tokens especiales [CLS]/[SEP]. La diferencia es deliberada: las representaciones esparsas se benefician de reducir variabilidad lexica, mientras que la atencion contextual aprovecha el texto casi intacto.



3. Baseline (Modulo 3): TF-IDF + clasificador

Se exploraron max_features (5.000, 20.000, sin limite), ngram_range ((1,1), (1,2)) y tres clasificadores (Naive Bayes, Regresion Logistica, SVM lineal) sobre una validacion interna del train (20%). Mejor configuracion: **MultinomialNB**, max_features = None, ngram_range = (1, 2) (25,400 features). El vectorizador se ajusto solo con train (sin data leakage). F1 macro en test = **0.8960**, accuracy = 0.8960.

Configuracion (validacion)	Modelo	F1 macro val.
mf=None, ng=(1, 2)	MultinomialNB	0.896
mf=20000, ng=(1, 2)	MultinomialNB	0.8954
mf=None, ng=(1, 2)	LinearSVC	0.8934
mf=20000, ng=(1, 1)	MultinomialNB	0.8929
mf=None, ng=(1, 1)	MultinomialNB	0.8929
mf=20000, ng=(1, 2)	LinearSVC	0.8921

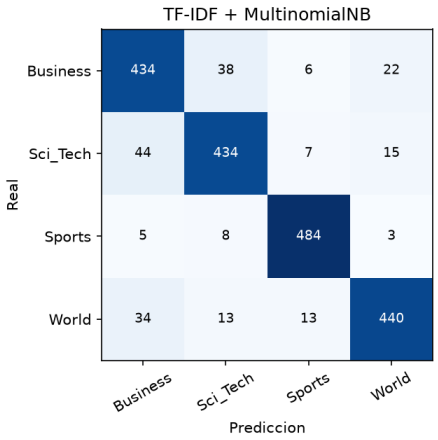
4. Solucion avanzada (Modulo 4): DistilBERT + LoRA

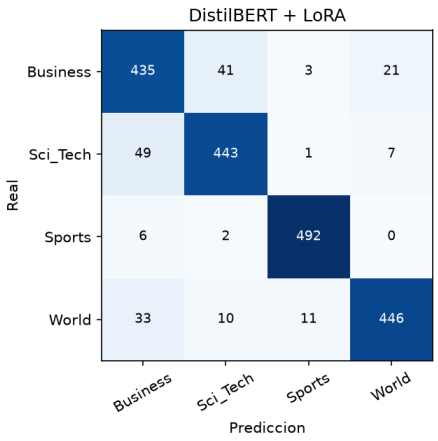
Se adapto distilbert-base-uncased (encoder de 6 capas y 12 cabezas de atencion) con LoRA: en lugar de actualizar todas las matrices mediante backpropagation, se congelan los pesos y se entrenan matrices de bajo rango (r = 8, alpha = 16) en las proyecciones query y value de la auto-atencion, mas la cabeza de clasificacion. Entrenables: 741,124 de 67,697,672 parametros (**1.09%**). Ciclo en PyTorch (Trainer de Hugging Face, optimizador AdamW, lr = 0.0002, 3 epocas, batch 32, precision mixta fp16, semilla 42). Perdida final: train 0.2724, validacion 0.2578. Tiempo de entrenamiento: 3.7 min en Apple MPS (GPU del Mac).

5. Evaluacion comparativa

Metrica	A: TF-IDF + MultinomialNB	B: DistilBERT + LoRA
Precision (macro)	0.8964	0.9091
Recall (macro)	0.8960	0.9080
F1 (macro)	0.8960	0.9082
Precision (weighted)	0.8964	0.9091
Recall (weighted)	0.8960	0.9080
F1 (weighted)	0.8960	0.9082
Accuracy	0.8960	0.9080

Ambos modelos se evaluaron sobre el mismo ag_news_test.csv (2.000 noticias, 500 por clase). Al estar las clases balanceadas, F1 macro y weighted coinciden y Accuracy es una metrica valida.





Eficiencia. TF-IDF: 0.2 s de entrenamiento en CPU y 0.00 s de inferencia sobre el test. LoRA: 219 s de entrenamiento en GPU y 8.7 s de inferencia (~1371x el tiempo de entrenamiento). Mejora de F1 macro: +0.0122.

Analisis de errores e interpretabilidad

El Transformer acierta 73 noticias que el baseline falla; el baseline acierta 49 que el Transformer falla. Confusion principal del baseline: Sci_Tech vs Business; del Transformer: Sci_Tech vs Business. Terminos mas influyentes del baseline por clase: Business: say, oil, price, company, new; Sci_Tech: microsoft, new, say, software, internet; Sports: win, game, season, team, night; World: say, iraq, kill, president, minister. Ejemplos corregidos por el Transformer (no se inspeccionaron pesos de atencion; la comparacion es por casos):

Texto (truncado)	Real	TF-IDF	LoRA
Producer sues for Rings profits. Hollywood producer Saul Zaentz sues the producers of The Lord of the Rings for $20m in royalties.	World	Business	World
EU, US Talks on Aircraft Aid Grounded. US and EU negotiators disagreed on Thursday about state aid for aircraft rivals Airbus and Boeing, winding up no closer on a sensitive issue that has gathered steam before the US pr	Business	World	Business
Atlantis "Evidence" Found in Spain, Ireland. In 360 B.C. the Greek philosopher Plato described an island he called Atlantis. Now contradicting new evidence claims the fabled city-state was based on a real place.	Sci_Tech	Sports	Sci_Tech
Barents Sea Under Threat from Fishing, Oil (Reuters). Reuters - The Arctic Barents Sea is under threat from overfishing, oil and gas exploration and Soviet-era radioactive waste, the U.N. Environment Program said on Tues	Sci_Tech	World	Sci_Tech
Coors' Donation to Own Campaign Draws Ire (AP). AP - A #36;500,000 donation by Republican beer baron Pete Coors to his own Senate campaign has triggered a new federal law that eases fund-raising restrictions for his Demo	World	Business	World

6. Conclusiones, limitaciones y mejoras

Hallazgos. Sobre AG News, el baseline TF-IDF + MultinomialNB alcanza F1 macro 0.8960 y el Transformer + LoRA 0.9082 (+0.0122); con 1.09% de parametros entrenables, el Transformer aporta una mejora moderada: el costo adicional se justifica solo si cada punto de F1 es valioso para el negocio. **Por que:** la clasificacion tematica de noticias depende en gran parte de vocabulario distintivo (nombres de empresas, deportes, paises), que TF-IDF captura bien; el Transformer suma semantica contextual y robustez ante sinonimos y vocabulario no visto (subpalabras), lo que ayuda en textos ambiguos entre Business y Sci_Tech o World y Business. **Limitaciones.** Un solo corpus en ingles, una semilla y un solo modelo base; textos cortos; no se midio variabilidad entre corridas; no se analizaron pesos de atencion. **Mejoras.** Probar r y modulos objetivo mayores, varias semillas con intervalos de confianza, RoBERTa/BERT-base, y analisis de interpretabilidad (SHAP o atencion).

Referencias

Zhang, X., Zhao, J., LeCun, Y. (2015). Character-level Convolutional Networks for Text Classification. | Vaswani et al. (2017). Attention Is All You Need. | Sanh et al. (2019). DistilBERT. | Hu et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. | Pedregosa et al. (2011). Scikit-learn.